

ИЗКУСТВЕНИ НЕВРОННИ МРЕЖИ И ЕВОЛЮЦИЯ НА РАЗЛИКИТЕ, ИЗПОЛЗВАНИ ЗА ПРОГНОЗИРАНЕ НА ВРЕМЕНИ РЕДОВЕ В РАЗПРЕДЕЛЕНА СРЕДА

ARTIFICIAL NEURAL NETWORKS AND DIFFERENTIAL EVOLUTION USED FOR TIME SERIES FORECASTING IN DISTRIBUTED ENVIRONMENT

П. Томов, В. Монов

Институт по информационни и комуникационни технологии, Българска академия на науките, ул. "акад. Георги Бончев", бл. 2, София 1113, тел. +359 2 9793237, e-mail: petyr.tomov@gmail.com

Abstract: This study will present a model for time series forecasting. The model consists of Artificial Neural Networks (ANN) trained with Differential Evolution (DE). The training is done in distributed computational environment. Time series forecasting is a complex process and demand development of effective and faster algorithms. The core of the model is ANN, which is fed with historical data. Selection of appropriate ANN training algorithm is a major problem in this forecasting approach. Two general possibilities are commonly used - exact numeric optimization methods and heuristic optimization methods. According to the heuristic applied, training can be done as distributed computing. In this case the output is much faster and more realistic, which helps to achieve better forecast.

Key words: forecasting, ANN, DE, distributed computing

1. ВЪВЕДЕНИЕ

Прогнозирането на времеви редове е процес на прогнозиране на бъдещите стойности в серия от данни, базирани на техните известни стойности в предходните моменти. Лицата, вземащи решения (ЛВР), са в позицията да предприемат много отговорни стъпки при формирането на стратегия и поемането на отговорност за взетите решения. Това най-вече важи при процесите за вземане на инвестиционни решения. Да се инвестира, това означава да се поема приемлив риск с очакване на определена печалба. Най-важният аспект на инвестициите е балансът между приема на риска и очакваната печалба. На валутния пазар (FOREX) основната търговия се извършва чрез обмен на валута. Валутите са най-волатилни по отношение на промяна в цената. По време на търговия, на такъв пазар като FOREX, трябва да се вземат три важни решения: 1. Цената ще тръгне нагоре или надолу; 2. Какъв е обемът за покупка или продажба; 3. Колко дълго да се запази отворена позиция. Дори и да звучи просто, в действителност е много трудно да се прецени смяната на посоката в цената, защото огромното количество фактори влияят върху него. Обемът на поръчката е пряко свързан с размера на поемания риск. Големият обем може да доведе до висока печалба, но ако посоката на цената се окаже неправилна, това може да причини големи загуби. Ако една позиция се запази по-дълго отворена, печалбата може да стане по-голяма или загубата да бъде възможно най-малка. Финансовото прогнозиране е най-важно за търговците на валутния пазар, поради високата динамика на цената.

Разработването на ефективни и надеждни финансови прогнози е трудна и сложна задача. Следователно, областта е от голямо значение за развитието и използването на самоорганизиращи се и самостоятелно обучаващи се системи за прогнозиране. Прилагането на ИНМ за прогнозиране на времеви редове в областта на

икономиката е разгледано от различни автори, например Dunis [1], Giles [2] и Moody [3]. Един общ метод използва така наречените Feed Forward Neural Networks (FFNN) (Haykin [4]). Мрежите от типа FFNN са много ефективни, но имат основен недостатък, а именно на тях им липсва краткосрочната памет. Този проблем може да се избегне чрез използване на така наречените Recurrent Neural Networks (RNN). RNN, от своя страна, водят до трудности поради своята сложност при обучението с точни числени методи. (Werbos [5]). Възможно решение е комбиниран подход за обучение на ИНМ от еволюционни алгоритми. Той е предложен от Yao [6] и няколко други автори. Еволюционните алгоритми показват значително по-добри резултати за оптимално търсене на сложни многомерни пространства с присъствието на много локални оптимуми. В тези случаи градиент-базирани методи са склонни да се блокират. (Holland [7]).

В настоящето изложение е предложен модел за прогнозиране на времеви редове с помощта на самообучаваща се система. Системата се основава на изкуствени невронни мрежи (ИНМ) и оптимизационен алгоритъм за еволюция на разликите (ЕР). Изчисленията се извършват в разпределена среда.

Изложението е организирано както следва: Раздел 2 дефинира проблема за прогнозиране на времеви редове и дава насоки за подходите, използвани при решаването му. Раздел 3 представя модела, основан на ИНМ и ЕР, като се засягат особеностите на алгоритмите, стоящи зад тях. Раздел 4 излага възможности за бъдещо развитие, даващо достатъчно насоки за доразвиване на изложените идеи. Раздел 5 представлява обобщение и заключение.

2. ОПИСАНИЕ НА ПРОБЛЕМА

В областта на прогнозирането на времеви редове има няколко специфични аспекти. Като начало, има поредица

от стойности със зависимости по оста на времето (време-стойност двойки). Стойностите във времевите редове не са независими стойности. Тези стойности са свързани помежду си по такъв начин, че по-новите стойности са следствие от по-старите. Например - курсът между EUR и USD. Изключително необичайно е отношението между тези две валути да се различават драстично в два последователни търговски дни. Съотношението между двете валути се променя плавно, но постоянно. Това отношение най-силно се влияе от процесите за търговия между Европа и САЩ.

Проблем при прогнозирането на финансови времеви редове е, знаейки последните стойности на цените, да се разработи прогнозен модел и с помощта на този модел да се оценяват бъдещите стойности на цените. При достатъчно надежен модел, прогнозираните стойности могат да бъдат използвани от ЛВР, за намаляване на инвестиционния риск.

ИНМ е математически модел на естествените невронни мрежи. Тя се състои от изкуствени неврони с набор от връзки между тях. Информацията се обработва от влизането в мрежата и се предава към вътрешните слоеве (неврони) до изхода. ИНМ са проектирани да бъдат самостоятелно адаптивни системи, способни да променят своята вътрешна структура на базата на външна или вътрешна информация, която постъпва по време на обучението. ИНМ се използват за моделиране на сложни връзки между входове и изходи (functional relation) или откриване на зависимост в набор от данни (data mining).

Идеята на ИНМ е вдъхновена от биологичната нервна система, разчитаща на неврони, аксони, дендрити и синапси. Обикновено ИНМ се състои от мрежа прости елементи за обработка, които заедно определят сложно глобално поведение, реализирано от връзките между елементите. От практическа гледна точка, ИНМ използва алгоритми за промяна на силата (тежестта) на връзките, за да се постигне желания поток на сигнали в мрежата.

ИНМ са доста подобни на естествените невронни мрежи по начина, по който отделните елементи обработват в паралел информацията. В модерните компютри ИНМ се съчетават с неадаптивни методи за постигане на по-добри практически резултати. Основното предимство на ИНМ е способността им да се „научи“ функция чрез наблюдение на конкретно подадени примери. Това е особено полезно, когато сложността на изследвания процес (или неговите данни) прави съставянето на такава функция, на ръка, твърде трудно.

ЕР е метод от популационните, еволюционни евристики за глобална оптимизация. Основата на ЕР е разработена от Kenneth Price и Rainer Storn[8] и тя се основава на класически генетични алгоритми (ГА). Евристика, като ЕР, не гарантира, че оптималното решение ще се намери. ЕР се използва при изследването на сложни за търсене пространства (в общия случай многомерни). ЕР може да се прилага предимно в непрекъснати проблеми (проблеми с реални числа). По-малко приложима е в целочислени проблеми, въпреки че не се изисква целевата функция да е диференцируема (условие, което е често изисквано в точните методи за оптимизация).


Подобно на класическите ГА, ЕР използва населението на кандидат-решенията и създава нови кандидат-решения. Това става чрез комбиниране на съществуващи такива, в съответствие с правилата на кръстосване, мутация и селекция (най-добрите кандидати оцеляват през поколения-

ята, съгласно стойностите на функцията за жизнеспособност). При оценяване на стойностите от целевата функция и избора на най-добрите кандидати, не е необходимо да се използва градиент.

При сравнение между ЕР и ГА основната разлика е в оператора мутация. При ЕР мутацията се основава на претеглен вектор-разлика. Това прави мутацията много по-ефективна от тази, използвана в ГА. На практика се получава промяна на всяка стойност на конкретния индивид в популацията. Недостатък на претегления вектор-разлика е трудността да се приложи при работата с целочислени стойности.

3. ОПИСАНИЕ НА МОДЕЛА

Предложеният математически модел е базиран на стандартна ИНМ и комбинирано обучение с ЕР, и обратно разпространение на грешката (ОРГ). Топологията на ИНМ е въпрос на изследователски интерес. Поради тази причина, топологията на мрежата се определя ръчно на отдалечения сървър. Връзките между невроните могат да бъдат - само напред, напред-назад и дори пълно-свързан (свързан с всички други неврони и със себе си). Невроните в модела използват линейна функция на активация и сигмоидна предавателна функция.

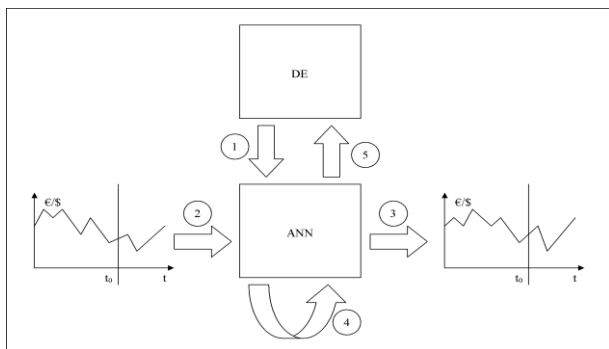


Фиг.1 – Концептуален модел на системата.

В ЕР, като вариация на генетичните алгоритми (ГА), всяка хромозома представя един набор от тежести за определена топология ИНМ. Както е показано на Фиг.1, при глобалната ЕР популация е представена на отдалечения сървър.


На всеки изчислителен възел (компютър клиент) се зарежда подмножество от глобалната популация (етап 1 на Фиг. 3). Последва извършване на локално, ЕР-ОРГ базирано, ИНМ обучение (стъпка 2 на Фиг. 3). На редовни интервали локалните компютри се свързват към отдалечения сървър. По време на тази връзка, локалната популация се обновява и локално получените оптимални стойности се докладват (стъпка 3 на Фиг. 3).

Поради високата степен на паралелизъм, ЕР няма теоретична граница за брой изчислителни възли. Като техническото ограничение (тясното място на системата) е отдалеченият сървър. Техническото ограничение на едновременните свързани клиенти е границата на сървъра. За сметка на това, не е необходимо всеки клиент да има постоянна връзка с отдалечения сървър. По този начин техническото ограничение лесно се преодолява. Всеки отдалечен изчислителен възел може да изчислява седмици и дори месеци наред, преди да се направи връзка със сървъра.




Фиг.2 – Обучение на ИНМ, базирано на ЕР.

Както е описано на Фиг. 2, еволюцията на разликите е процес на обучение, който се състои от пет основни стъпки: 1. Зареждане набор от тегла (хромозома) в ИНМ; 2. Зареждане на примерни за обучение в ИНМ; 3. Изчисляване на прогнози; 4. Изчисляване на общата допусната прогнозна грешка (по-стари данни имат по-малко въздействие върху изчислената грешка); 5. Оценка на жизнеността на хромозомата. Всеки набор от тегла (хромозоми) се зарежда в ИНМ, след това всички входни стойности се разпространяват в мрежата. Всички стойности в изхода на мрежата се сравняват с очакваните стойности и тази разлика се използва за образуване на общата грешка, постигната при конкретен набор от тегла. Изчислената обща грешка се използва, като стойност на жизнеспособност в ЕР популацията. Основната цел на ЕР базираната оптимизация е да се сведе до минимум общата грешка, допусната от ИНМ. Тъй като процесът на обучение е в реално време (нови данни постъпват постоянно), то минимизирането на грешки е непрекъснат процес.

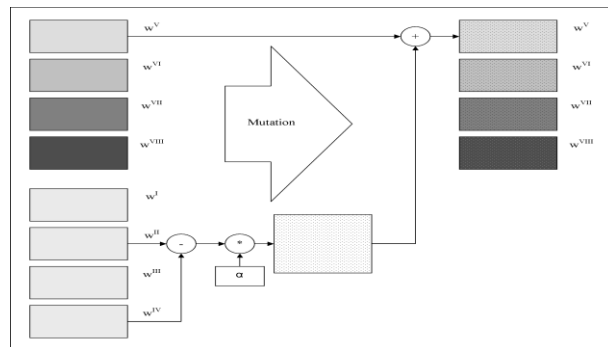


Фиг.3 – Изчисленията се извършват на локалната машина, като сървърът единствено разпределя задачите.

Всички изчисления се правят локално, както е показано на Фиг. 3. Локалните изчисления се състоят от ЕР базирано обучение - кръстосване и мутация. И двете операции се извършват, както е илюстрирано на Фиг. 4 и Фиг. 5. Избират се родителски хромозоми за кръстосване, като изборът се извършва по правило, както е в класическите ГА. Операцията за кръстосване се счита за разрушителна в процеса на обучение на ИНМ. Поради тази причина, кръстосването се регулира като параметър. След кръстосването се извършва мутация. Класическа мутация при ЕР е сума между модифицираната хромозома и претеглен вектор-разлика (разлика между други две произволно избрани хромозоми, умножен по коефициент за тежест).




Фигура 4 – Процедура за кръстосване при метода за Еволюция на разликите.



Фиг.5 – Процедура за мутация при метода за Еволюция на разликите.

За паралелно обучение, копия на ИНМ се изпращат до всеки локален изчислителен възел. Проблемът с бавна скорост на обучение, когато ИНМ се обучава с ЕР, може да бъде решен чрез периодично превключване към обучение с ОРГ. Този процес се извършва чрез отстраняване на всички обратни връзки, както е илюстрирано на Фиг. 6.



Фиг.6 – Подход за изключване на обратните връзки, когато се извършва хибридно обучение с ЕР и ОРГ.

Нивото на сходимост при обучението може да се използва като индикатор за превключване между ЕР и ОРГ. ОРГ може да се приеме като по-особен вариант за мутация.

4. БЪДЕЩИ РАЗРАБОТКИ

С предложения модел изследвания може да се направят в следните направления: 1. Анализ на ускорението от паралелно пресмятане; 2. Изучаване на променливи топологии на ИНМ; 3. Изследване на различни възможности за представяне на входно-изходната информация; 4. Глобална реализация на ЕР при подбор на

популация за локално обучение на ИНМ. Увеличаването на броя изчислителни възли не винаги е гаранция, че резултатите ще се получат по-бързо. Това е предмет на допълнителни изследвания, как точно паралелното смятане се отразява в сходимостта на обучението. Стандартно е обучението на ИНМ с фиксирана топология. От изследователски интерес е как процесът на обучение може да бъде променен, така че да се приложи над ИНМ с променяща се топология. Добре известно е, че по-малките ИНМ се обучават по-бързо от по-големите. Ако се въведе правило за нарастване на мрежата, може да се получи по-добра сходимост на обучението. Представянето на информацията на входа на ИНМ влияе сериозно на топологията и размера на мрежата. По-добро представяне на информацията може да доведе до по-малък ИНМ и по-добра сходимост при обучение. В разпределените изчисления разделянето на изчислителните задачи в няколко части дава допълнителни възможности. В случай на ЕР съществено е как ще се контролира глобалната популация и правилата, по които се формират локалните популации. Много важен параметър за разследване е колко често локалните популации да бъдат синхронизирани с глобалната. При реализацията на разпределените изчисления, за обучение на ИНМ с ЕР, би било интересно да се експериментира методът за инцидентно включване и изключване на възли, описан в [9][10].

5. ЗАКЛЮЧЕНИЕ

ЕР, като алгоритъм за обучение, предпазва ИНМ от катастрофално забравяне. Също така, ЕР позволява обучение на ИНМ с обратни връзки. Не представлява проблем, ако обучаващите примери се подават в последователен ред. Няма ограничения за броя паралелни процеси при обучението. Злонамерените изчислителни възли (потребители, които злонамерено модифицират резултатите от изчисленията) не са проблем, те са дори предимство, тъй като биха направили ЕР популациите още по-богати, като генотип. Основният недостатък на ИНМ, използвани за прогнозиране на времеви редове, е бавното темпо на обучение. С използването на разпределени изчисления процесът на обучение става значително по-ефективен. От икономическа гледана точка, чрез използването на добре организиран (маломощен), централизиран сървър, може да се постигне изчислителната мощност на супер компютър.

БЛАГОДАРНОСТИ

This work was supported by private funding of Velbazhd Software LLC.

ЛИТЕРАТУРА

1. Dunis, C.L. & Williams, M., Modelling and trading the eur/usd exchange rate: Do neural network models perform better? *Derivatives Use, Trading and Regulation*, 8(3), pp. 211--239 (2002)
2. Giles, C.L., Lawrence, S. & Tsoi, A.C., Noisy time series prediction using a recurrent neural network and grammatical inference. *Machine Learning*, 44(1/2), pp. 161--183 (2001)
3. Moody, J.E., Economic forecasting: Challenges and neural network solutions. *Proceedings of the International Symposium on Artificial Neural Networks*, Hsinchu, Taiwan (1995)

4. Haykin, S., *Neural Networks, A Comprehensive Foundation*. Prentice-Hall, Inc., 2nd edition (1999)
5. Werbos, P., Backpropagation through time: what it does and how to do it. *Proceedings of the IEEE*, 78(10), pp. 1550--1560 (1990)
6. Yao, X., Evolving artificial neural networks. *Proc of the IEEE*, 87(9), pp. 1423--1447 (1999)
7. Holland, J., *Adaptation In Natural and Artificial Systems*. The University of Michigan Press (1975)
8. Storn, R.; Price, K. Differential evolution - a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization* 11, 341--359 (1997)
9. Balabanov, T., Zankinski, I., Barova, M., Strategy for Individuals Distribution by Incident Nodes Participation in Star Topology of Distributed Evolutionary Algorithms, *Cybernetics and Information Technologies*, Vol. 16 No 1, ISSN: 1314-4081, 2016.
10. Balabanov, T., Zankinski, I., Barova, M., Distributed Evolutionary Computing Migration Strategy by Incident Node Participation, *International Conference on Large-Scale Scientific Computing*, 10th International Conference, LSSC 2015, Sozopol, Bulgaria, June 8-12, ISBN 978-3-319-26519-3, pp. 203-209, 2015.